

Trabajo Práctico 7

Camussoni Francesco^{1,*}

¹ Instituto Balseiro, Universidad Nacional de Cuyo

*camussonif@gmail.com

ABSTRACT

Se implementó una red neuronal recurrente con características LSTM para predecir la cantidad de pasajeros de avión según la fecha del dataset airline-passengers. Finalmente, se comparó su rendimiento con una red neuronal recurrente de capas densas.

LSTM

Se utilizó el set de datos de airline-passengers el cual establece la cantidad de pasajeros que viajaron en avión según determinado mes de cierto año como se muestra en la **Figura 4**.




Figure 1. Datos originales.

En primera instancia se normalizaron los datos entre 0 y 1 y se reformatearon los datos de la siguiente manera:

$$\begin{cases} X = (x(t), x(t+1), \dots, x(t+l-1)) \\ Y = x(t+l) \end{cases}$$

En donde l es un entero positivo que determina la retrosección de los datos. Luego, se agregó un ruido con media 0 y dispersión de 0.2 al vector Y .

A continuación, se separó el set de datos en training y test con un 50% de los datos originales en cada caso. Finalmente, en cuanto al preprocesado de datos, se modificó la dimensión de los datos para que puedan ser utilizados por la red LSTM que requiere el siguiente tipo de input: [batch, timesteps, feature]. 'batch' no es necesario identificarlo a priori y timesteps=1 en nuestro caso. 'feature' será igual a la retrosección elegida.

Luego, se definió la siguiente arquitectura:

Model: "red_recurrente_LSTM"

	Layer (type)	Output Shape
=====	LSTM (LSTM)	(None, 16)
=====	Dense (Dense)	(None, 1)
=====	Total params: 1,169	

Trainable params: 1,169
Non-trainable params: 0

En donde los parámetros se dejaron por defecto `activation="tanh"`, `recurrent_activation="sigmoid"`, `kernel_initializer="glorot_uniform"`, `recurrent_initializer="orthogonal"`, `bias_initializer="zeros"`,

Así, se entreno a la red neuronal por 200 épocas, un learning rate de $1e-3$, una retrosección de 1 y MSE como función de costo en donde se obtuvieron los resultados que se muestran en las **Figuras 2 y 3**.




Figure 2. Costo para los datos de training según la época.




Figure 3. Datos originales y predicción sobre los datos de training y sobre los datos de test.

En donde se observa un gran rendimiento en la predicción con un error de 0.0015 en los datos de training y 0.0058 en los datos de test según MSE

A continuación se realizó el mismo entrenamiento modificando la retrosección de 1 a 25 en donde en cada instancia se obtuvo el error en los datos de test obteniendo el resultado que se muestra en la **Figura ??**.



Figure 4. Loss sobre los datos de test en función de la retrosección.

En donde no se observa un comportamiento definido, si no más bien un comportamiento azaroso o de ruido. Probablemente el la elección de la retrosección no tenga influencia en el loss de test pero si en las predicciones a futuro o Forecasting

Capas densas

Finalmente, se implementó una arquitectura similar en donde se reemplazó la capa LSTM por una capa densa de la misma cantidad de neuronas con activación relu en donde se obtuvieron los resultados que se muestran en las **Figuras 5 y 6**.

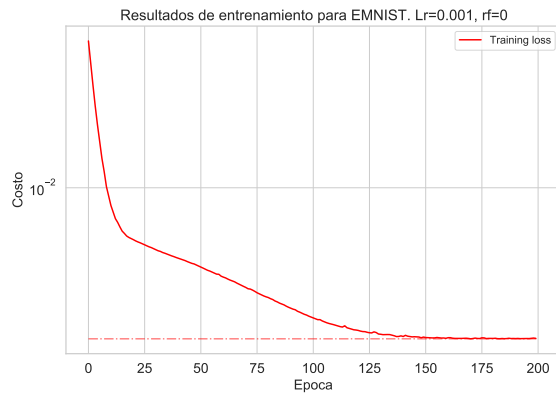


Figure 5. Costo para los datos de training según la época.




Figure 6. Datos originales y predicción sobre los datos de training y sobre los datos de test.

En donde se observa un rendimiento menor que al utilizar capas LSTM. Esto es debido, como se explicó anteriormente, a que las mismas están bien diseñadas para la predicción de información dependiente del tiempo, dado que puede haber cierto lag de duración desconocida entre los eventos importantes o relevantes de la información en donde la capa LSTM realizó un balance olvidar parte de lo aprendido e incorporar la nueva información, mientras que las capas densas no tienen esta propiedad.